



Uso de redes neurais baseadas na rede pré treinada YOLO para tomada de decisão na transposição de obstáculos para autônomos biomiméticos não guiados

Lenin Cristi

CMCC – Universidade Federal do ABC (UFABC)
Santo André – SP – Brasil

lenin.cristi@aluno.ufabc.edu.br

Resumo. *O presente artigo trata da viabilidade da utilização de redes neurais de detecção de objetos para tomada de decisão autônoma de robôs de exploração espacial em terreno hostil e não mapeado.*

Sumário

1. Introdução	4
1.1. O Desafio dos robôs atuais de exploração espacial	4
1.2. Visão geral de caso: Marte	4
1.3. Rodas e terrenos	5
1.4. Alternativas evolucionárias	5
1.5. Aprendizado e mobilidade	6
1.6. Proposta do macroprojeto	7
1.7. Fases do projeto	7
1.8. Fase deste artigo dentro do projeto	7
2. Metodologia	8
2.1. Descrição do experimento	8
2.2. Montagem do cartão de dados do modelo	8
2.3. Amostra & coleta dos dados	8
2.3.1. Captura & Local	8
2.3.2. Equipamento & Organização	9
2.3.3. Quantidade de imagens	10
2.3.4. Considerações éticas	10
2.3.5. Limitações	10
2.4. Pré-processamento das imagens	10
2.4.1. Classificação e anotação das imagens	10
2.4.2. Processamento	11
2.4.3. Aumento dos dados	12
2.5. Treinamento	12
2.5.1. Setup do ambiente de treino	12
2.5.2. Repositório	12
2.5.3. Treinamento	13
3. Resultados	14
3.1. Treino 3	14
3.2. Treino 11	14
4. Discussão	15
5. Conclusão	16
6. Referências bibliográficas	17

6.1. Artigos.....	17
6.2. Referências gerais	18
6.3. Referências técnicas.....	19

1. Introdução

1.1. O Desafio dos robôs atuais de exploração espacial

A exploração e mapeamento de terrenos desconhecidos, sejam acidentados, altamente irregulares, ravinas, encostas e mesmo cavernas é um desafio para robôs de exploração, seja essa espacial ou terrestre.

A adoção da biomimética na construção de robôs guarda forte relação com a mudança de paradigma de eficiência para adaptabilidade (Fang et al, 2022), onde desenhos com patas e mais similares ao de animais adaptados a sobreviver e explorar terrenos acidentados são utilizados.

O desenvolvimento de técnicas de aprendizado de máquina para mapeamento de terrenos e detecção de objetos aliadas a miniaturização e barateamento de sensores e chips embarcados abre uma oportunidade de uso destas duas áreas (Wang et al, 2021) na construção de veículos não guiados que aliando biomimética e aprendizado profundo tem uma capacidade de sobrevivência e exploração inexistente nas gerações de veículos de exploração anteriores.

1.2. Visão geral de caso: Marte

Marte é um destino de robôs de exploração espacial a pelo menos 50 anos, com dezenas de missões bem-sucedidas e veículos que em muitos aspectos foram pioneiros de múltiplos avanços tecnológicos aplicados simultaneamente (Smithsonian, 2022).

Abaixo uma visão geral das últimas missões americanas com veículos guiados a Marte






Missão	Imagem	Data de Lançamento	Data de Chegada	Objetivos	Veículo Utilizado	Fonte de Energia	Número de Rodas	Tempo de Vida Esperado do Veículo	Dimensões do Veículo
Mars Pathfinder		4 de dezembro de 1996	4 de julho de 1997	Coleta de dados geológicos e atmosféricos	Sojourner Rover	Painéis solares	6	Cerca de 7 sols (cerca de 3 meses)	65 cm x 48 cm x 30 cm
Spirit		10 de junho de 2003	4 de janeiro de 2004	Coleta de dados geológicos e atmosféricos	Mars Exploration Rover	Painéis solares	6	90 sols (cerca de 90 dias)	2,3 m x 1,5 m x 1,6 m
Opportunity		7 de julho de 2003	25 de janeiro de 2004	Coleta de dados geológicos e atmosféricos	Mars Exploration Rover	Painéis solares	6	90 sols (cerca de 90 dias)	2,3 m x 1,5 m x 1,6 m
Curiosity		26 de novembro de 2011	6 de agosto de 2012	Coleta de dados geológicos e atmosféricos	Curiosity Rover	Gerador termoelétrico de radioisótopos	6	Mais de 14 anos	3,0 m x 2,7 m x 2,2 m
Perseverance		30 de julho de 2020	18 de fevereiro de 2021	Coleta de amostras de solo e rocha, busca por sinais de vida passada	Perseverance Rover	Gerador termoelétrico de radioisótopos	6	Mais de 14 anos	3,0 m x 2,7 m x 2,2 m

Tabela 1: Missões americanas com veículos guiados a Marte desde 1996 (NASA Mars Exploration Rovers, 2023 & NASA Mars Exploration Rovers Missions, 2023)

Mas mesmo os mais avançados robôs de exploração enviados a Marte têm limitações quando considerado seu envelope de mobilidade, excluindo de seu roteiro de mapeamento e testes a coleta em cavernas, ravinas e mesmo encostas pelo perigo de se acidentar ou perder contato com a base no caso de um bloqueio de antena.

Por mais engenhosas que sejam as soluções empregadas nestes veículos em rodas, aderência, estabilidade e controle nestes robôs, seu envelope de mobilidade torna a espeleologia nestes equipamentos ainda que a espeleologia terrestre, um desafio quanto a solução de problemas de transposição de terreno e mobilidade.

Quanto a comunicação são veículos guiados remotamente, o que nos equipamentos movidos a energia solar subtrai ainda mais tempo útil do período de exposição diário ao sol do veículo. Sendo 13 minutos o tempo médio de ida e volta de um sinal de rádio da Terra a Marte para cada conjunto de comandos e sabendo que as órbitas planetárias são elípticas e não síncronas entre a Terra e Marte, temos o tempo mínimo de 3 minutos e máximo de 22 minutos para a ida e volta do sinal.

1.3. Rodas e terrenos

Um robô com rodas é reconhecidamente eficiente em terreno plano com pouca ou nenhuma quebra de terreno grave, tem boa estabilidade com 6 rodas, tem boa eficiência energética por roda por metro e pode se mover do ponto A para o ponto B sem interferência constante do piloto se os dois pontos tiverem acesso relativamente limpo e visado.

Por outro lado, quando encontra obstáculos íngremes mesmo dos mais simples como degraus positivos e negativos com parede quase vertical, ou obstáculos mais difíceis como acessos reduzidos a cavernas e galerias ou ravinas curtas, mas sem fundo, a capacidade de exploração desse tipo de autônomo dependendo da sua construção e número de rodas, fica seriamente comprometida.

Se for semiautônomo e não reconhecer seu envelope de mobilidade, pode perder locomoção, se acidentar ou mesmo perder contato com a base, dependendo da profundidade e grossura das paredes da estrutura que estiver explorando ou tiver caído.

Numa outra frente, mesmo guiado interativamente sua construção em geral não permite uma liberdade de movimento e recursos para vencer o obstáculo para o qual não foi previamente projetado para transpor, o que pode se tornar um fim da linha para a exploração naquele sentido do terreno ainda que interativa e para todos os efeitos, seu centro de gravidade é fixo na sua geometria.

1.4. Alternativas evolucionárias

Consideremos agora um robô semiautônomo de exploração espacial para terreno hostil, mas que seja baseado na forma de animais bem adaptados a sobreviver em terrenos hostis e desconhecidos como os artrópodes chilopoda ou diplopoda terrestres, estamos falando de utilizar princípios de biomimética na sua concepção e construção.



Imagem 1: Artrópodes extintos e modernos. Do canto superior esquerdo: †trilobita, †eurípteros, escorpião, siri, Quilópode (Chilopoda) e borboleta (Adaptado do artigo sobre artrópodes, Wikipedia)

Um autônomo baseado num artrópode possui uma construção mais complexa em termos energéticos, mas com um envelope de mobilidade radicalmente superior. Suas articulações o tornam um equipamento de geometria variável, com recursos de mobilidade para transpor uma variedade ampla de obstáculos e mesmo alterar seu centro de gravidade para vencer determinados desafios, algo impossível a um robô de geometria fixa atual.

Biomimética é um campo de estudo que se baseia na observação e no aprendizado da natureza para desenvolver soluções tecnológicas inovadoras e eficientes. A biomimética envolve a análise e a compreensão de como as formas de vida na Terra evoluíram e se adaptaram às suas condições ambientais, e como esses princípios podem ser aplicados para resolver problemas complexos em diferentes áreas, como engenharia, arquitetura, medicina e design. (Adaptado do artigo sobre Biomimética, Wikipédia)

1.5. Aprendizado e mobilidade

Consideremos agora que esse autônomo que já tem a geometria de um artrópode da classe chilopoda, possa aprender os movimentos de um. Aprender com movimentos reais que chilopodas terrestres usam para vencer ravinas sem fundo, degraus positivos e negativos, fazer nado curto serpenteado, entre outros. Ainda que esse robô seja semiautônomo, e opere num terreno completamente não mapeado como uma galeria fechada por exemplo, ele teria em teoria a capacidade de mapear o terreno, reconhecendo obstáculos à sua frente e determinar o melhor movimento para transpô-lo, e em caso extremo, entender que aquele obstáculo não é transponível, reconhecendo seu próprio envelope de manobra.

Essa capacidade de reconhecimento por aprendizado de máquina à primeira vista pode soar distante, no entanto, a adoção de aprendizado de máquina na exploração espacial não é nova. O primeiro registro de uso de aprendizado de máquina nesse campo foi na sonda Deep Space 1, onde o algoritmo empregado era capaz de detectar mal

funcionamento no equipamento embarcado. Em outro exemplo nos robôs de exploração marcianos, é utilizado um algoritmo que melhora a comunicação entre o veículo e a Terra.

“In a similar vein, AI has successfully been used in space rover system software to enhance the communication between the rover and Earth during missions in outer space” (Jaeck, 2022)

1.6. Proposta do macroprojeto

A visão geral do projeto é construir um veículo de exploração semiautônomo com desenho baseado em chilopodas terrestres e com inteligência artificial embarcada para poder mimetizar movimentos desses animais para vencer obstáculos em terreno hostil e não mapeado, com comunicação eventualmente funcional.

1.7. Fases do projeto

O projeto como um todo teria várias fases de estudo de viabilidade antes da construção propriamente dita:

- Viabilidade da impressão do exoesqueleto
- Viabilidade da construção do conjunto de mobilidade de cada seção do corpo
- Viabilidade da inteligência artificial de mapeamento
- Viabilidade da inteligência artificial de manobra
- Viabilidade do embarque do núcleo de código, processamento de sinais e modelos de aprendizado treinados em microcomputadores compactos

Este conjunto de estudos é capaz de demonstrar a viabilidade ou não dos itens críticos do projeto, permitindo traçar um plano de construção em fases e com orçamento previsível em cada fase.

1.8. Fase deste artigo dentro do projeto

Este documento se propõe ao item “Viabilidade da inteligência artificial de manobra”, onde se determina se as redes neurais artificiais atuais no estado-da-arte para detecção de objetos em imagens são capazes de detectar diferentes tipos de obstáculos na altura de visão do autônomo e gerar uma saída que permita determinar um movimento para transpor esse obstáculo.

2.1. Descrição do experimento

2.1. Descrição do experimento

A proposta consiste em treinar uma rede neural artificial de detecção de objetos baseada na YOLO versão 8 para detectar obstáculos, para que o veículo seja capaz de reconhecer um obstáculo e determinar o movimento necessário para transpô-lo (ou num caso limite, determinar que ele não é transponível pela capacidade de manobra do autônomo).

2.2. Montagem do cartão de dados do modelo

O cartão de dados do modelo deverá ser montado determinando fontes de dados, limites, entradas e saídas do modelo proposto, baseado no padrão do artigo “Model Cards for Model Reporting” (Mitchell et al, 2019).

Uma implementação deste trabalho para um modelo de detecção de Iris está disponível em <https://drive.google.com/file/d/1bsWbokp9AkIH2ANjCfmjqEzzxO1CNbMu/view>. Uma outra implementação feita pelo Google para modelos de detecção de objetos está disponível em <https://modelcards.withgoogle.com/object-detection>.

2.3. Amostra & coleta dos dados

2.3.1. Captura & Local

A captura de imagens para o treinamento do modelo se deu em campo, em condições naturais de iluminação entre 12h e 16h do outono. O local escolhido foi o parque público “Clube Recreativo CERET” localizado na Zona Leste da cidade de São Paulo (Coordenadas: 23° 33' 29.96" S 46° 33' 23.23" W), foram coletados 105 itens entre fotos e vídeos de obstáculos do parque.

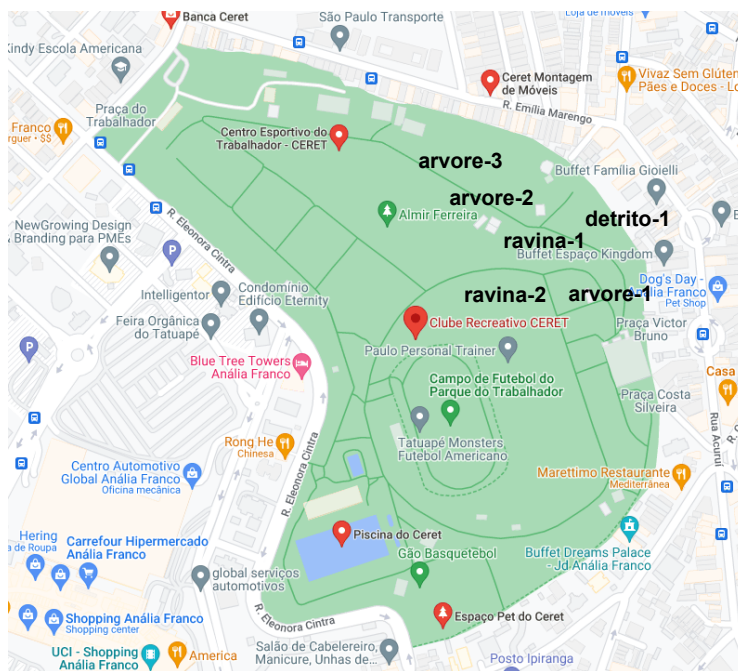


Imagem 2: Mapa do parque com os locais de coleta dos grupos de imagens. (Adaptado do Google Maps)

Cada ponto no mapa representa um conjunto de capturas para um obstáculo.

2.3.2. Equipamento & Organização

O equipamento utilizado foi uma câmera grande angular de 16MP, com balanço de brancos e ISO no automático montada num tripé que mantinha o centro da lente a 12,5cm do solo, com angulação ao chão que permitia enquadrar um objeto a 20cm de distância da lente.



Imagem 3: Visão de cima da organização do equipamento usada em todas as capturas de imagem, note a distância do post-it



Imagem 4: Ângulo de visão da câmera no obstáculo "detrito-1", note que o post-it está enquadrado no solo da tela

Foram adicionados marcadores nas imagens para permitir estabelecer a profundidade de campo posteriormente:

- Marcador rosa: 1m
- Marcador laranja: 2m
- Marcador verde: 3m



Imagem 5: Visão geral de como foram capturadas as imagens dos obstáculos, com os marcadores de profundidade

2.3.3. Quantidade de imagens

Foram capturados 6 conjuntos de imagens, um para cada ponto no mapa (Imagem 2). Cada conjunto de captura consiste em três conjuntos menores de pelo menos 3 fotos cada, na mesma distância do obstáculo, mas com variações de 15cm a 25cm para cada lado do ponto inicial de captura. Foram capturados portanto ao menos 9 imagens de cada obstáculo.

2.3.4. Considerações éticas

Imagens com pessoas ou rostos que foram capturadas em campo foram descartadas do treinamento e não constam da base publicada. Após a remoção o treinamento contou com 102 imagens.

2.3.5. Limitações

O número de imagens capturadas em campo e a baixa variedade de obstáculos podem representar um empecilho para o treinamento da rede neural e fazer com que ela não seja capaz de generalizar novos obstáculos.

2.4. Pré-processamento das imagens

2.4.1. Classificação e anotação das imagens

Após a captura das imagens, foi utilizada a ferramenta Roboflow para anotação das imagens capturadas, e foram gerados dois conjuntos de dados públicos com as imagens:

- Object Detection 1
 - 72 imagens de treino, 20 de validação e 10 de teste
 - Objetos anotados: arvore, ravina e detritos
 - Local: <https://universe.roboflow.com/lnncrsufabc91b9b4e9/obstacle-detection-1/dataset/1>
- Object Detection 2
 - 14 imagens de treino, 4 de validação e 2 de teste
 - Objetos anotados: arvore

- Local: <https://universe.roboflow.com/lnncrsufabc91b9b4e9/obstacle-detection-2/dataset/1>



Imagem 6: Exemplo de imagem anotada para detritos



Imagem 7: Exemplo de imagem anotada para arvore



Imagem 8: Exemplo de imagem anotada para ravina

2.4.2. Processamento

As imagens serão reduzidas para 640x640 pixels, com método preencher.

2.4.3. Aumento dos dados

As não foram multiplicadas por métodos de aumento de conjunto de treino.

2.5. Treinamento

Foi utilizada a rede neural YOLOv8 como ponto de partida para o treinamento, uma descrição detalhada desta rede pode ser encontrada no índice da sua documentação aqui <https://docs.ultralytics.com/> o repositório utilizado como base para o código está aqui <https://github.com/ultralytics/ultralytics>

2.5.1. Setup do ambiente de treino

O ambiente de treino foi montado sobre o gerenciador de pacotes e ambientes virtuais miniconda <https://docs.conda.io/en/latest/miniconda.html> com os seguintes componentes:

- Python 3.7 como base <https://www.python.org/>
- Numpy, Pandas, Scikit-Learn e Jupyter
- Pytorch <https://pytorch.org/> habilitado para treino em GPU (utilizado a placa GTX 1650 SUPER da NVIDIA)
- YOLOv8

Com o ambiente instalado foram utilizadas as opções de treino da YOLO em linha de comando <https://docs.ultralytics.com/usage/cli/>, foi atestado o sucesso da instalação utilizando uma imagem padrão do YOLO para detecção



Imagem 9: Imagem de teste utilizada




Imagem 10: Imagem de teste utilizada depois de passar pela rede YOLO, note os quadros de detecção com legendas e com a probabilidade do objeto ser o detectado de fato

O ambiente completo do experimento para reprodução pode ser encontrado no repositório do experimento.

2.5.2. Repositório

Foi criado um repositório de código para o experimento no github: <https://github.com/Inncrs/ArthropodaObjectDetection>

Organização do repositório:

- camera-label-square : Imagens dos obstáculos separadas em pastas
- datasets: Conjuntos de imagens Roboflow em formato YOLOv8 já anotados
- docs: Pasta de documentos
- runs: Modelos treinados

Assim como os dois conjuntos de imagens anotadas no Roboflow, o repositório de código no github é público, ambos sob licença GNU e ambos podem ser usados para reproduzir ou estender o experimento atual.

2.5.3. Treinamento

Foram treinados um conjunto de modelos para a detecção de objetos, mas somente dois foram incluídos no repositório, os dois mais bem sucedidos em termos de completude de resultado e material de saída. Dentro da pasta run as pastas train3 e train11 correspondentes aos treinamentos 3 e o 11.

O treinamento 3 incluiu todas as três classes (arvore, detritos e ravina) o treinamento 11 incluiu uma classe somente (arvore).

```

Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
97/100   2.3G      nan      nan      nan      15         640: 100%|██████████| 5/5 [00:03<00:00, 1.52it/s]
      Class  Images  Instances  Box(P  R      mAP50  mAP50-95): 100%|██████████| 1/1 [00:00<00:00, 2.36it/s]
      all    20      39      0      0      0      0

Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
98/100   2.34G      nan      nan      nan      15         640: 100%|██████████| 5/5 [00:03<00:00, 1.53it/s]
      Class  Images  Instances  Box(P  R      mAP50  mAP50-95): 100%|██████████| 1/1 [00:00<00:00, 2.37it/s]
      all    20      39      0      0      0      0

Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
99/100   2.31G      nan      nan      nan      19         640: 100%|██████████| 5/5 [00:03<00:00, 1.51it/s]
      Class  Images  Instances  Box(P  R      mAP50  mAP50-95): 100%|██████████| 1/1 [00:00<00:00, 2.41it/s]
      all    20      39      0      0      0      0

Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
100/100  2.3G      nan      nan      nan      29         640: 100%|██████████| 5/5 [00:03<00:00, 1.48it/s]
      Class  Images  Instances  Box(P  R      mAP50  mAP50-95): 100%|██████████| 1/1 [00:00<00:00, 2.34it/s]
      all    20      39      0      0      0      0

100 epochs completed in 0.119 hours.
Optimizer stripped from runs\detect\train3\weights\last.pt, 6.2MB
Optimizer stripped from runs\detect\train3\weights\best.pt, 6.2MB

Validating runs\detect\train3\weights\best.pt ...
Ultralytics YOLOv8.0.84 Python-3.7.16 torch-1.13.1 CUDA:0 (NVIDIA GeForce GTX 1650 SUPER, 4096MiB)
Model summary (fused): 168 layers, 3006233 parameters, 0 gradients, 8.1 GFLOPs
      Class  Images  Instances  Box(P  R      mAP50  mAP50-95): 100%|██████████| 1/1 [00:00<00:00, 2.06it/s]
      all    20      39      0      0      0      0

Speed: 0.4ms preprocess, 18.0ms inference, 0.0ms loss, 0.7ms postprocess per image
Results saved to runs\detect\train3

```

Imagem 11: Últimas 3 iterações de treino da rede neural para o treino 3. Note as versões do YOLO, Python, PyTorch e o dispositivo CUDA utilizado.

3. Resultados

Infelizmente nenhum dos dois conjuntos treinados conseguiu generalizar as imagens capturadas fazendo as marcações, mas não conseguindo marcar em novas imagens os obstáculos treinados.

3.1. Treino 3

Conjuntos de imagens do treino 3 na entrada e saída do treino



Imagem 12: Imagens marcadas



Imagem 13: Imagens previstas sem detecção

3.2. Treino 11

Conjuntos de imagens do treino 11 na entrada e saída do treino



Imagem 14: Imagens marcadas



Imagem 15: Imagens previstas sem detecção

4. Discussão

Os modelos construídos no experimento não foram capazes de generalizar a detecção dos obstáculos propostos, a saber: Base de árvores, detritos de cimento armado e ravinas horizontais fundas e rasas utilizadas como base. Apesar de utilizado um modelo no estado-da-arte (SOTA) para detecção de objetos, neste experimento não conseguimos utilizar transfer learning para ensiná-lo a reconhecer obstáculos no ângulo de captura, condições de iluminação e visada próximas das que um robô de exploração capturaria as imagens.

A rede YOLO é eficiente em detectar animais, objetos, veículos e mesmo uma mistura destes objetos em imagens e filmes, mas para utilizá-la para transferência de aprendizado nesse ângulo baixo, específico de veículos terrestres de baixa ou baixíssima estatura, pode ser necessário:

- Uma ingestão maior de imagens, com maior diversidade de horário e iluminação natural da utilizada aqui;
- Aumento do conjunto de dados com ângulos e cortes de obstrução aleatórios para simular oclusão parcial dos objetos
- Pré-processamento das imagens para tons de cinza, preto e branco e saturação para evidenciar objetos
- Camadas especiais de convolução para determinar as bordas de objetos específicos neste ângulo mais baixo, caso nenhuma das anteriores funcione

5. Conclusão

A história da engenharia espacial se confunde com as grandes descobertas da humanidade de maneira silenciosa. O experimento atual não foi capaz de gerar um modelo que generalize detecção de obstáculos, mas gerou uma quantidade de dados e conhecimento que pode ser utilizada para tarefas mais simples, e por que não, mais importantes como detectar carros saindo da pista, enfermos deixando os quartos do hospital de madrugada, modo de vida noturno de vida selvagem para recuperar habitats, encontrar nos dias mais frios do inverno paulista pessoas em situação de rua procurando abrigo para que equipes possam ampará-los e evitar as trágicas mortes que temos anualmente na cidade por hipotermia. Em suma, qualquer coisa mais simples e mais útil que espeleologia espacial.

Mas então fica dúvida, por que ir? Essa é exatamente uma das razões e um dos objetivos da exploração espacial: Estender a fronteira do conhecido. Ampliar as margens do possível, aqui na Terra.

E neste processo historicamente as tecnologias mais inovadoras e as soluções mais radicais encontradas foram usadas aqui. Um exemplo: O projeto SETI que busca vida extraterrestre nunca encontrou sinal de vida inteligente, mas sua necessidade de clusters de computação que não existiam nas décadas de 70 e 80, levou a construção de computadores distribuídos e isso foi o embrião da computação em nuvem, usada hoje em todos os telefones inteligentes do planeta, desde as aplicadas em todas as redes sociais até aos aplicativos críticos hospitalares, bancários, governamentais e acadêmicos.

Esse experimento é um de muitos passos.

6. Referências bibliográficas

6.1. Artigos

Fang, J., Zhuang, Y., Liu, K., Chen, Z., Liu, Z., Kong, T., Xu, J., Qi, C.,
A Shift from Efficiency to Adaptability: Recent Progress in Biomimetic Interactive Soft Robotics in Wet Environments. Adv. Sci. 2022, 9, 2104347
<https://doi.org/10.1002/advs.202104347>

Jiankun Wang, Weinan Chen, Xiao Xiao, Yangxin Xu, Chenming Li, Xiao Jia, Max Q.-H. Meng,
A survey of the development of biomimetic intelligence and robotics, Biomimetic Intelligence and Robotics, Volume 1, 2021, 100001, ISSN 2667-3797
<https://doi.org/10.1016/j.birob.2021.100001>

Linda Jaeck,
Challenges and Opportunities of AI in Outer Space, How AI is enabling new frontiers in Mars exploration, 2022
<https://www.internetjustsociety.org/cosmonaut/challenges-and-opportunities-of-ai-in-outer-space>

Smithsonian Air and Space Museum
Exploring the Red Planet with Robots, Jul 14, 2022
<https://airandspace.si.edu/stories/editorial/exploring-red-planet-robots>

NASA Mars exploration rovers, 2023
<https://mars.nasa.gov/mer/>

NASA Mars Exploration Rovers Missions, 2023
https://mars.nasa.gov/mars-exploration/missions/?page=0&per_page=99&order=date+desc&search=

Zhong-Qiu Zhao, Member, IEEE, Peng Zheng, Shou-tao Xu, and Xindong Wu, Fellow, IEEE
Object Detection with Deep Learning: A Review, 2019

<https://arxiv.org/pdf/1807.05511.pdf&usg=ALkJrhhpApwNJOmg83O8p2Ua76PNh6tR8A>

Xiongwei Wua, Doyen Sahooa , Steven C.H. Hoia,

Recent Advances in Deep Learning for Object Detection, 2019

<https://arxiv.org/pdf/1908.03673.pdf>

Margaret Mitchell, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben

Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, Timnit Gebru

Model Cards for Model Reporting, 2019

<https://arxiv.org/pdf/1810.03993.pdf>

Franco Tedeschi, Giuseppe Carbone,

Design Issues for Hexapod Walking Robots, 2014

<https://www.mdpi.com/2218-6581/3/2/181>

6.2. Referências gerais

Biomimética

A **biomimética** é uma área da ciência que tem por objetivo o estudo das estruturas biológicas e das suas funções, procurando aprender com a Natureza, suas estratégias e soluções, e utilizar esse conhecimento em diferentes domínios da ciência.

<https://pt.wikipedia.org/wiki/Biomim%C3%A9tica>

Artrópodes

Artrópodes são um filo de animais invertebrados que possuem exoesqueleto rígido e vários pares de apêndices articulados, cujo número varia de acordo com a classe.

<https://pt.wikipedia.org/wiki/Artr%C3%B3pode>

Quilópodes (Chilopodes)

Chilopoda, conhecidos popularmente como centopeias ou lacraias, é uma das classes pertencente ao subfilo Myriapoda.

<https://pt.wikipedia.org/wiki/Quil%C3%B3pode>

Redes neurais artificiais

Em ciência da computação e campos relacionados, redes neurais artificiais (português brasileiro) ou redes neuronais artificiais (português europeu) (RNAs) são modelos computacionais inspirados pelo sistema nervoso central de um animal (em particular o cérebro) que são capazes de realizar o aprendizado de máquina bem como o reconhecimento de padrões. Redes neurais artificiais geralmente são apresentadas como sistemas de "neurônios interconectados, que podem computar valores de entradas", simulando o comportamento de redes neurais biológicas.

https://pt.wikipedia.org/wiki/Rede_neural_artificial

Transfer Learning (Transferência de aprendizado)

Transfer learning é um campo de pesquisa em aprendizado de máquina que se concentra em aplicar o conhecimento adquirido ao resolver uma tarefa a uma tarefa relacionada. Por exemplo, o conhecimento adquirido ao aprender a reconhecer carros poderia ser aplicado ao tentar reconhecer caminhões. Esse tópico está relacionado à literatura psicológica sobre transferência de aprendizagem, embora as ligações práticas entre os dois campos sejam limitadas. Reutilizar/transferir informações de tarefas previamente aprendidas para novas tarefas tem o potencial de melhorar significativamente a eficiência de aprendizado.

https://en.wikipedia.org/wiki/Transfer_learning

6.3. Referências técnicas

Object detection

<https://towardsdatascience.com/object-detection-with-neural-networks-a4e2c46b4491>

<https://towardsdatascience.com/deep-learning-for-object-detection-a-comprehensive-review-73930816d8d9>

YOLO

<https://towardsdatascience.com/yolo-you-only-look-once-real-time-object-detection-explained-492dc9230006>

<https://blog.devgenius.io/training-yolov8-on-custom-dataset-d2edae447c9>